

ESCOM-IPN
Pattern Recognition

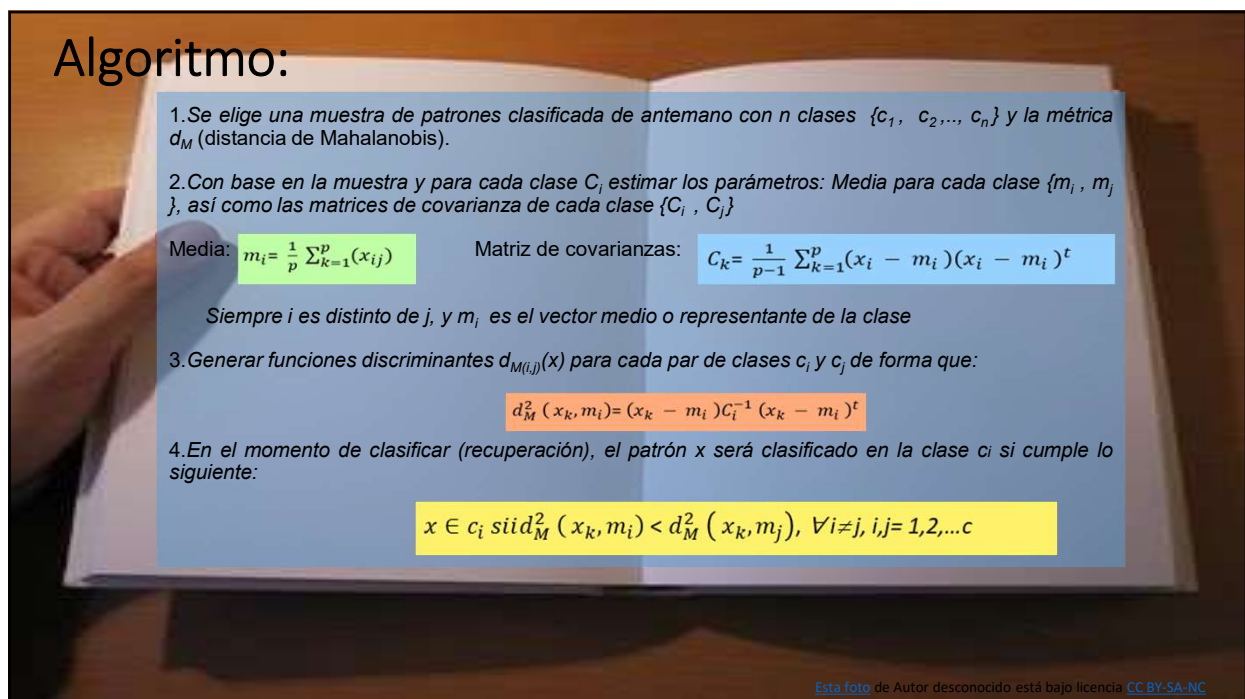
Ej. Clasificador paramétrico Bayesiano

(Diseño de un clasificador, para una FD para clases con Distribución Gaussiana o **DM**)

M. En C. María Elena Cruz Meza
mcruzme@ipn.mx

Esta foto de Autor desconocido está bajo licencia CC BY-SA-NC

1



Algoritmo:

1. Se elige una muestra de patrones clasificada de antemano con n clases $\{c_1, c_2, \dots, c_n\}$ y la métrica d_M (distancia de Mahalanobis).
2. Con base en la muestra y para cada clase C_i estimar los parámetros: Media para cada clase $\{m_i, m_j\}$, así como las matrices de covarianza de cada clase $\{C_i, C_j\}$
Media: $m_i = \frac{1}{p} \sum_{k=1}^p (x_{ik})$ Matriz de covarianzas: $C_k = \frac{1}{p-1} \sum_{k=1}^p (x_i - m_i)(x_i - m_i)^t$
Siempre i es distinto de j , y m_i es el vector medio o representante de la clase
3. Generar funciones discriminantes $d_{M(i,j)}(x)$ para cada par de clases c_i y c_j de forma que:
 $d_M^2(x_k, m_i) = (x_k - m_i) C_i^{-1} (x_k - m_i)^t$
4. En el momento de clasificar (recuperación), el patrón x será clasificado en la clase c_i si cumple lo siguiente:
 $x \in c_i \text{ si } d_M^2(x_k, m_i) < d_M^2(x_k, m_j), \forall i \neq j, i, j = 1, 2, \dots, c$

Esta foto de Autor desconocido está bajo licencia CC BY-SA-NC

2

Ej. Suponiendo los siguientes datos:

1. Sea un sistema biclase $\{c_1, c_2\}$, k patrones, distribuidos en un espacio bidimensional, tal como se muestra en el siguiente esquema:

C_1	$x_{1,1}$	1	3	1	2	3
	$x_{1,2}$	2	3	5	2	3

C_2	$x_{2,1}$	6	6	7	8	8
	$x_{2,2}$	4	3	4	4	5

- Calcular la separabilidad entre las clases
- Diseñar un clasificador basado en la información a priori del problema.
- Dado el patrón desconocido $x=(4,5)$, probar su pertenencia a una de las dos clases, conforme la fd diseñada en a).

3

Resolviendo...

Fase de Aprendizaje

Dado de que se tiene el conocimiento previo de ambas clases la cardinalidad de los patrones y sus rasgos x_1 y x_2). Se pueden estimar los vectores media y las matrices de covarianza correspondientes a cada una de las clases como sigue:

Para cada c_k , siendo k el número de patrones pertenecientes a cada clase c_k , desde $k=1$ hasta p patrones

- Media: $m_i = \frac{1}{p} \sum_{k=1}^p (x_{ij})$
- Matriz de Covarianza: $C_k = \frac{1}{p-1} \sum_{k=1}^p (x_i - m_i)(x_i - m_i)^t$

4

Solución:

2. Estimando los vectores media y las matrices de covarianza correspondientes a cada una de las clases como sigue:

Para C1:

$$C_1 = \frac{1}{s-1} (x + a)^n = \frac{1}{4} \left[\begin{pmatrix} -1 \\ -1 \end{pmatrix} \begin{pmatrix} -1 & -1 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} -1 \\ 2 \end{pmatrix} \begin{pmatrix} -1 & 2 \end{pmatrix} + \begin{pmatrix} 0 \\ -1 \end{pmatrix} \begin{pmatrix} 0 & -1 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} \right]$$

$$m_1 = \frac{1}{s} \sum_{k=1}^s (x_{ij}) = \frac{1}{5} \begin{bmatrix} 10 \\ 15 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$$

$$C_1 = \frac{1}{4} \left[\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & -2 \\ -2 & 4 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \right]$$

$$C_1 = \frac{1}{4} \begin{pmatrix} 4 & -1 \\ -1 & 6 \end{pmatrix}$$

$$C_1 = \begin{pmatrix} 1.0 & -0.25 \\ -0.25 & 1.5 \end{pmatrix}$$

5

2. Estimando los vectores media y las matrices de covarianza correspondiente para la segunda de las clases, como sigue:

Para C2:

Media:

$$m_1 = \frac{1}{s} \sum_{k=1}^s (x_{ij}) = \frac{1}{5} \begin{bmatrix} 35 \\ 20 \end{bmatrix} = \begin{bmatrix} 7 \\ 4 \end{bmatrix}$$

Matriz de Covarianza

$$C_2 = \frac{1}{s-1} (x + a)^n = \frac{1}{4} \left[\begin{pmatrix} -1 \\ 0 \end{pmatrix} \begin{pmatrix} -1 & 0 \end{pmatrix} + \begin{pmatrix} -1 \\ -1 \end{pmatrix} \begin{pmatrix} -1 & -1 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \end{pmatrix} \right]$$

$$C_2 = \frac{1}{4} \left[\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \right]$$

$$C_2 = \frac{1}{4} \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix}$$

$$C_2 = \begin{pmatrix} 1.0 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}$$

6

3. Dado lo anterior, podemos diseñar un clasificador bayesiano sabiendo que un patrón desconocido x_k , puede clasificarse de acuerdo con la forma:

$$p(y=c_i/x) = \frac{p(x/y=c_j)P(y=c_j)}{p(x)}$$

Donde:

$$p(x) = \sum_{j=1}^c p(x/y=c_j)P(y=c_j)$$

Y por la regla de decisión establecida como:

$$x \in C_i \text{ sii } p(y=c_j/x) > p(y=c_i/x), \forall i \neq j, i, j = 1, 2, \dots, c$$

Notemos que $p(x)$ no aporta nada a la decisión, por lo que optaremos por una forma alternativa para clasificar al vector:

$$x \in C_i \text{ sii } p(x/y=c_i)p(y=c_i) > p(x/y=c_j)p(y=c_j), \forall i \neq j, i, j = 1, 2, \dots, c$$

7

3. Diseñando el clasificador...

Normalmente las distribuciones de densidad de probabilidad se eligen Normales o Gaussianas, así, debemos calcular la distancias a cada clase, en este caso, dado que las matrices de covarianzas son distintas, podemos diseñarlo usando la distancia de Mahalanobis, de la forma:

$$d_M^2(x_k - m_i) = (x_k - m_i) C_2^{-1} (x_k - m_i)^t$$

$$x \in C_i \text{ sii } d_M^2(x_k - m_i) < d_M^2(x_k - m_j), \quad \forall i \neq j, i, j = 1, 2, \dots, c$$

Con $\{m_i, m_j\}$ y $\{C_i, C_j\}$ que corresponden a la Media y la Matriz de Covarianza estimada para cada clase, para toda i distinta de j

8

Fase de Aprendizaje

a) La separabilidad entre las dos clases, la podemos obtener a partir de (10.28), (10.29) y (10.31) [consultar el capítulo 10 de Pajares y que fue copartido], obtenemos la separabilidad entre ambas clases:

Diver_{1,2}:

$$Diverg_{12} = 27.978 \quad \cos \alpha_{12} = 0 \quad J_{12} = 1.986$$

Dado que solo son dos clases, la separabilidad entre ellas no aporta gran información, para conocer esto es necesaria una relación entre más de dos clases.

9

Fase de Aprendizaje

4. Probando el clasificador para $x_k=(4,5)$, debemos obtener las distancias a las dos clases:

Para C1: $d_M^2(x_k - m_1) = (x_k - m_1) C_1^{-1} (x_k - m_1)^t$

$$d_M^2(x_k - m_1) = (2, 2) \begin{pmatrix} 1.0435 & 0.1739 \\ 0.139 & 0.6957 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} = 8.35$$

Para C2: $d_M^2(x_k - m_2) = (x_k - m_2) C_2^{-1} (x_k - m_2)^t$

$$d_M^2(x_k - m_1) = (-3, 1) \begin{pmatrix} 2.0 & -2.0 \\ 2.0 & 4.0 \end{pmatrix} \begin{pmatrix} -3 \\ 1 \end{pmatrix} = 34.00$$

Concluimos que:

$$x \in C_1 \text{ dado que } d_M^2(x_k - m_1) < d_M^2(x_k - m_2)$$

10



- ❖ Hemos diseñado un clasificador Bayesiano basado en la información a priori que se tiene de las clases, y en la estima de parámetros como la media y la matriz de covarianza.
- ❖ Podemos constatar que el clasificador Bayesiano es un método clásico que se basa en el supuesto de que el problema de la decisión de enfoca en términos probabilísticos y que todas las probabilidades relevantes resultan conocidos.
- ❖ El clasificador surge cuando las probabilidades a priori son iguales, por ello se usa la dMahalanobis, a diferencia del Método Euclidiano.

Conclusiones

11



Referencias

- Gonzalo Pajares Martinsanz & Jesús M. de la Cruz García. Visión por computadora: imágenes digitales y aplicaciones. Ed. Alfaomega Ra-Ma. 2002
- Ma. Elena Cruz Meza, Notas del curso de Reconocimiento de Patrones. Escom-IPN, 2005
- J. Kittler (revisado y ampliado por GTI-IIIE), 1/09/2002. [Problemas en el diseño de un Sistema de RP \(diseño de una fd\) para clases con distribución Normal Gaussiana](#)

Esta foto de Autor desconocido está bajo licencia CC BY-ND

12